

TP regression


Emerick Lafortune

1 Introduction

La régression est une technique statistique fondamentale dans l'analyse des données, utilisée pour modéliser et comprendre les relations entre une variable dépendante et une ou plusieurs variables indépendantes. En permettant de prédire des valeurs et d'évaluer l'impact des facteurs sur un résultat, elle permet d'explorer les relations entre les variables, formuler des hypothèses et prédire des comportements futurs, ce qui en fait un pilier de l'analyse des données.

2 Compromis biais-variance en régression

Dans le cadre de l'étude des données de prostate, nous allons tester plusieurs modèles classiques et comparer leur performance afin d'évaluer la valeur du log de l'antigène lpsa. Ci-dessous, la forme de nos données :



lcpvol	lweight	age	lbph	svi	lcp	gleason	pgg45	lpsa	train
-0.579818	2.76946	50	-1.38629	0	-1.38629	6	0	-0.430783	T
-0.994252	3.31963	58	-1.38629	0	-1.38629	6	0	-0.162519	T
-0.510826	2.69124	74	-1.38629	0	-1.38629	7	20	-0.162519	T
-1.20397	3.28279	58	-1.38629	0	-1.38629	6	0	-0.162519	T
0.751416	3.43237	62	-1.38629	0	-1.38629	6	0	0.371564	T
-1.04982	3.22883	50	-1.38629	0	-1.38629	6	0	0.765468	T
0.737164	3.47352	64	0.615186	0	-1.38629	6	0	0.765468	F
0.693147	3.53951	58	1.53687	0	-1.38629	6	0	0.854415	T
-0.776529	3.53951	47	-1.38629	0	-1.38629	6	0	1.04732	F
0.223144	3.24454	63	-1.38629	0	-1.38629	6	0	1.04732	F
0.254642	3.60414	65	-1.38629	0	-1.38629	6	0	1.26695	T
-1.34707	3.59868	63	1.26695	0	-1.38629	6	0	1.26695	T
1.61343	3.02286	63	-1.38629	0	-0.597837	7	30	1.26695	T
1.47705	2.99823	67	-1.38629	0	-1.38629	7	5	1.34807	T

Figure 1: Dataframe prostate

Le modèle classique de base est la régression linéaire, où l'on exprime une variable en particulier (variable cible) par rapport aux autres variables (variables

explicatives). Les méthodes avant et arrière consistent, pour la méthode avant, à ajouter une à une nos variables explicatives pour voir si elles apportent des informations pour l'expression de notre variable cible, ou pour la méthode arrière, à commencer avec toutes les variables et à retirer celles qui impactent peu l'expression de la variable cible. L'importance des variables est mesurée grâce au calcul de leur p-value. Une p-value faible (proche de 0) indique une variable de grande importance, tandis que celles à p-value forte (proche de 1) sont les premières retirées pour la méthode arrière.

Après avoir isolé la variable cible des variables explicatives, nous pouvons déterminer un résumé pour connaître les p-values :

	coef	std err	t	P> t	[0.025	0.975]
lcavol	0.5616	0.085	6.601	0.000	0.393	0.731
lweight	0.6363	0.171	3.725	0.000	0.297	0.976
age	-0.0208	0.010	-1.991	0.049	-0.041	-4.7e-05
lbph	0.0939	0.054	1.743	0.085	-0.013	0.201
svi	0.7636	0.239	3.189	0.002	0.288	1.239
lcp	-0.1066	0.089	-1.194	0.236	-0.284	0.071
gleason	0.0652	0.103	0.635	0.527	-0.139	0.269
pgg45	0.0042	0.004	1.092	0.278	-0.003	0.012

Figure 2: Résumé donnant les valeurs des p-values

D'après le résumé, nous déduisons que lcavol et lweight sont les variables ayant le plus fort impact sur lpsa. Les variables svi et lbph ont également un fort poids sur notre variable cible. Cependant, nous remarquons que lcp, gleason et pgg45 ont des p-values d'un ordre de grandeur cent fois supérieur à celles des variables citées précédemment. Ainsi, dans le cadre de notre sélection basée sur la méthode arrière, nous retirons ces variables dont le poids est négligeable par rapport au reste.

Une évaluation avant et après avoir retiré les trois variables de faible poids montre que l'erreur quadratique et la valeur du R^2 restent quasiment les mêmes, justifiant ainsi leur retrait du modèle. Les deux figures suivantes montrent la faible augmentation de la valeur de l'erreur quadratique moyenne en retirant les variables à faible poids :

Mean Squared Error: 0.3469917891761402
 R^2 Score: 0.757517513020498

Figure 3: Évaluation du modèle avec toutes les variables explicatives

Nous allons maintenant comparer notre modèle linéaire aux modèles lasso et ridge, qui sont plus précis théoriquement.

Tandis que la régression linéaire est basée sur l'établissement d'une relation entre y et les différents coefficients de nos variables X_i , la régression Ridge utilise

```
Mean Squared Error: 0.3528570945913284
R² Score: 0.7534187594236306
```

Figure 4: Évaluation du modèle en retirant pgg45, lcp et gleason

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

Figure 5: Modèle de régression linéaire

un facteur de correction avec un terme en λ servant à minimiser l'erreur. Ce terme est utile pour minimiser le surapprentissage, surtout lorsque le nombre d'observations est supérieur au nombre de variables et que les variables présentent des colinéarités multiples. Cela n'étant pas notre cas, notre modèle linéaire devrait présenter des résultats similaires au modèle ridge.

$$\text{Minimize} \left(\sum (y - \hat{y})^2 + \lambda \sum \beta_i^2 \right)$$

Figure 6: Modèle de régression ridge

On peut voir que dans notre cas, nous avons trouvé une valeur d'erreur quadratique moyenne supérieure pour ridge que pour le modèle linéaire, mais selon le critère du R^2 , le ridge a un meilleur score que le modèle linéaire.

```
Mean Squared Error: 0.34871931522500876
R² Score: 0.7563102947930982
```

Figure 7: Évaluation du modèle ridge

Le modèle lasso présente également un terme de correction, mais il est plus utilisé lorsque le nombre de variables est important, car le terme de correction sélectionne le groupe de variables ayant le plus d'impact sur notre variable cible. Dans notre cas, nous obtenons une erreur quadratique importante et un critère du R^2 bien plus bas qu'avec les modèles linéaires et ridge. Cela montre que le modèle lasso est le moins performant dans le cadre de nos données, car nous cherchons à minimiser l'erreur quadratique moyenne et à maximiser le R^2 .

Ainsi, la comparaison des différents modèles donne le schéma suivant, où le modèle minimisant l'erreur dans notre cas est le modèle linéaire.

$$\text{Minimize } \left(\sum (y - \hat{y})^2 + \lambda \sum |\beta_i| \right)$$

Figure 8: Modèle de régression lasso

```
Mean Squared Error: 1.137259701476356
R^2 Score: 0.2052677632220039
```

Figure 9: Évaluation du modèle lasso

```
Linear Regression - CV MSE: 0.5782738071166469, Test MSE: 0.32289924481878285, Test R^2: 0.7743537041226178
Ridge Regression - CV MSE: 0.6111491591481572, Test MSE: 0.34871931522500876, Test R^2: 0.7563102947930982
Lasso Regression - CV MSE: 1.4071321212103909, Test MSE: 1.137259701476356, Test R^2: 0.2052677632220039
```

Figure 10: Évaluation des différents modèles

3 Conclusion

Dans l'étude des données de prostate, nous avons montré l'importance de l'utilisation de critères afin de vérifier d'une part la pertinence de nos modèles et d'autre part d'optimiser nos observations. L'utilisation de plusieurs modèles et des critères R^2 et de l'erreur quadratique moyenne nous a permis d'évaluer nos modèles et de choisir le modèle le plus pertinent à l'aide de nos mesures de précision.