

TP ACP biostats

Emerick Lafortune

1 Introduction

L'analyse en composantes principales (ACP) est une technique statistique utilisée pour réduire le nombre de dimensions de nos données tout en préservant le maximum d'information possible. Ainsi elle a pour utilité de pouvoir simplifier l'analyse de ces données grâce à la diminution du nombre de variables présentes. Enfin l'ACP est une méthode qui permet de pouvoir plus facilement exprimer les relations entre nos données et leur structure grâce à la simplification visuelle que diminuer le nombre de dimension permet. L'ACP peut servir d'étape de prétraitement avant d'autres techniques d'analyse comme la classification ou la régression.

2 Les crabes

Le dataset suivant représente 5 différentes familles de crabe de sexe mâle ou femelle représenté par les lettres M et F et de couleur Bleu ou orange par les lettres B et O.

Index	sp	sex	index	FL	RW	CL	CW	BD
0	B	M	1	8.1	6.7	16.1	19	7
1	B	M	2	8.8	7.7	18.1	20.8	7.4
2	B	M	3	9.2	7.8	19	22.4	7.7
3	B	M	4	9.6	7.9	20.1	23.1	8.2
4	B	M	5	9.8	8	20.3	23	8.2
5	B	M	6	10.8	9	23	26.5	9.8
6	B	M	7	11.1	9.9	23.8	27.1	9.8
7	B	M	8	11.6	9.1	24.5	28.4	10.4
8	B	M	9	11.8	9.6	24.2	27.8	9.7
9	B	M	10	11.8	10.5	25.2	29.3	10.3
10	B	M	11	12.2	10.8	27.3	31.6	10.9
11	B	M	12	12.3	11	26.8	31.5	11.4
12	B	M	13	12.6	10	27.7	31.7	11.4
13	B	M	14	12.8	10.2	27.2	31.8	10.9

Figure 1: dataset des crabes selon les différentes espèces

En réalisant l'ACP dans un premier temps avec 2 composantes principales on n'arrive pas vraiment à pouvoir reconnaître de pattern précis après avoir tracé le résultat de l'ACP La figure ci-dessous montre justement cette ACP réalisée sans aucun ajustement via un plot classique réalisé par matplotlib:




Figure 2: ACP tracée via un plot classique

Bien qu'il soit possible de voir une certaine répartition, cette dernière est peu représentée et on ne voit pas encore l'apparition de quelque cluster. Pour rendre plus visible cette information, on trace l'ACP avec biplot afin de pouvoir avoir sur un même graphique les composantes principales ainsi que les différentes variables analysées qui sont au nombre de 5 : FL, RW, CL, CW, BD qui sont les différentes familles de crabes. Tandis que le texte en vert montre le placement par rapport aux axes des différentes familles, où leur placement vers la droite montre une corrélation positive par rapport à la composante principale 1, l'orientation des flèches rouges ainsi que leur direction montre l'influence des 5 variables sur les différentes composantes principales. Les flèches étant toutes de même longueur leur influence est la même, cependant celles étant dirigées vers le haut ont une plus forte corrélation positive sur la composante principale 2 tandis que celles dirigées vers la droite, une forte corrélation positive sur la composante principale 1. Cependant le positionnement des observations le long de l'axe x et proche de 0 selon l'axe y montre que la majeure partie des observations et de la donnée est retranscrite par la composante principale 1 et seulement une petite partie de cette donnée dépend de la composante principale 2. Ce graphique présente néanmoins la limitation suivante : il ne permet pas de pouvoir différencier les différentes observations sous forme de groupes, de clusters.

Afin d'améliorer la visualisation des différents clusters on a implémenté l'algorithme des k-moyennes pour $k=5$ et on a ajusté l'échelle selon l'axe y pour améliorer la visibilité, étant donné qu'on est proche de 0 selon l'axe y on s'est limité à une échelle entre 2 et -2. On voit donc l'apparition de 5 clusters différents sur le graphique ci-dessous répartis en longueur selon leur corrélation à la composante principale 1. Ainsi l'utilisation de l'algorithme des k-moyenne avec l'ajustement de l'échelle permet de pouvoir mieux identifier les clusters.

Une autre méthode pour pouvoir potentiellement améliorer la représentation des différents groupes consiste à augmenter le nombre de composantes principales afin de pouvoir voir si cela rajoute certaines informations qui changent la répartition des différents clusters. Pour cela on peut tracer sur un graphique




Figure 3: biplot de l'ACP avec 2 composantes principales




Figure 4: biplot de l'ACP avec 2 composantes principales avec cluster k-means k=5

à trois dimensions réalisé avec trois composantes principales le résultat de nos observations afin de voir si l'ajout d'une nouvelle composante principale a un ajout d'informations conséquent, capable de changer la forme de nos clusters. Le graphique ci dessous montre que l'ajout d'une composante principale, change un peu la répartition des clusters mais de manière non significative: ils restent globalement alignés selon l'axe défini par la composante principale 1. Ainsi on fait le choix de se limiter à 2 axes car la majorité de l'information est perçue avec 2 composantes principales uniquement.

Le tracé du cercle de corrélation permet d'avoir une vision plus globale de la contribution de chaque variable aux composantes principales ainsi que la relation des différentes variables entre elles. Les variables FL BD CL et CW étant très proche de l'angle 0, elles déterminent principalement la composante principale 1 et ont peu d'effet sur la composante principale 2 contrairement à RW qui a un plus grand effet sur la composante principale 2 que le reste des variables.




Figure 5: biplot 3 dimensions représentant l'ACP avec 3 composantes principales

De plus le faible angle entre FL, BD, CL et CW 2 à 2 montre à nouveau que 2 composantes principales seraient assez pour conserver la très grande majorité de l'information. Concernant la caractérisation des mâles/femelles des crabes oranges et bleus, on peut voir deux distinctions réalisées par le cercle des corrélations entre les groupes qui ont un angle très proche de zéro et entièrement déterminés par la composante principale 1 et qui de plus ont une très forte valeur selon cette composante principale 1 (marquée par l'éloignement à 0) CL et CW, un deuxième groupe avec une valeur en composante principale 1 beaucoup plus faible et une valeur non proche de zéro en composante principale 2 RW, FL, BD. La composante principale 1 peut servir de distinction male femelle tandis que la 2 bleu/orange.




Figure 6: cercle de corrélations

3 Single nucleotide polymorphism

Le dataset suivant est composé de lignes contenant des listes de scalaires qui sont assimilables à des génomes ainsi que différents types de populations nommés CEU, GIH, LWK, MKK, TSI et YRI. Après nettoyage des valeurs manquantes dans notre base de données nous pouvons réaliser une ACP pour les 6 variables

que sont les différentes familles.

	CEU				GIH			
[-0.9884893 1.00002016 -0.84261089 ... 0.32371686 -1. ...	[-0.9884893 1.00002016 -0.84261089 ... 0.32371686 -1. ...				[-0.9884893 1.00002016 -0.84261089 ... 0.32371686 -1. ...			
0.63392164	0.63392164				0.63392164			
[-0.9884893 1.00002016 -0.84261089 ... 0.32371686 0. ...	[-0.9884893 1.00002016 -0.84261089 ... 0.32371686 0. ...				[-0.9884893 1.00002016 -0.84261089 ... 0.32371686 0. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 1.79998669 0. ...	0.52246614 1.00002016 -0.84261089 ... 1.79998669 0. ...				0.52246614 1.00002016 -0.84261089 ... 1.79998669 0. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 0.32371686 -1. ...	0.52246614 1.00002016 -0.84261089 ... 0.32371686 -1. ...				0.52246614 1.00002016 -0.84261089 ... 0.32371686 -1. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 1.79998669 -1. ...	0.52246614 1.00002016 -0.84261089 ... 1.79998669 -1. ...				0.52246614 1.00002016 -0.84261089 ... 1.79998669 -1. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...	0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...				0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 1.79998669 1. ...	0.52246614 1.00002016 -0.84261089 ... 1.79998669 1. ...				0.52246614 1.00002016 -0.84261089 ... 1.79998669 1. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...	0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...				0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 1.79998669 0. ...	0.52246614 1.00002016 -0.84261089 ... 1.79998669 0. ...				0.52246614 1.00002016 -0.84261089 ... 1.79998669 0. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...	0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...				0.52246614 1.00002016 -0.84261089 ... 0.32371686 0. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 1.79998669 1. ...	0.52246614 1.00002016 -0.84261089 ... 1.79998669 1. ...				0.52246614 1.00002016 -0.84261089 ... 1.79998669 1. ...			
0.63392164	0.63392164				0.63392164			
0.52246614 1.00002016 -0.84261089 ... 0.32371686 -1. ...	0.52246614 1.00002016 -0.84261089 ... 0.32371686 -1. ...				0.52246614 1.00002016 -0.84261089 ... 0.32371686 -1. ...			
0.63392164	0.63392164				0.63392164			

Figure 7: données des génomes selon différentes populations

Afin de réaliser cette ACP il faut appliquer à notre dataframe la fonction `.apply(lambda x: x.explode()).astype(float)` afin qu'il puisse transformer les différentes listes de scalaires en scalaires simple car l'ACP ne peut pas s'appliquer à des listes de scalaires comme éléments. Nous réalisons l'ACP pour 2 composantes principales et obtenons le biplot suivant :




Figure 8: biplot de l'ACP avec 2 composantes principales

Il est difficile de pouvoir reconnaître une tendance à travers ce biplot entorme de répartition des différents on peut voir la similitudes de certaines variables entre elles en particulier des variables représentant les populations (génomes) de même continent. Nous allons donc essayer de l'optimiser afin de pouvoir voir si des clusters se forment. Premièrement avec un algorithme nous allons calculer la variable expliquée en fonction du nombre de composantes principales pour voir si nous avons bien le nombre optimal de composantes principales. Notre algorithme nous permet de voir que 2 représente le nombre de composantes principales optimal donc nous allons utiliser l'algorithme des kmoyennes pour pouvoir améliorer la clusterisation des différents groupes. On voit l'apparation

de 6 clusters.




Figure 9: biplot de l'ACP avec 3 composantes principales avec cluster k-means $k=6$

De plus l'utilisation de 3 composantes principales ne semble pas d'après le graphique en 3 dimensions apporter une meilleure séparation des différents clusters. IL reste à essayer le cercle de corrélation.




Figure 10: biplot de l'ACP avec 2 composantes principales avec cluster k-means pour $k=6$

Le cercle de corrélation montre lui des infos beaucoup plus précises, par la proximité entre les différentes variables il forme 3 groupes avec les génomes provenant d'un même continent ayant le plus de similitudes entre eux. Le placement des différents axes ainsi que le clustering avec $k=3$ permettent de pouvoir conjecturer que le génome GHI (indien) est un mélange des génomes africain et causien qui eux sont très différents.




Figure 11: cercle de corrélation pour l'ACP à 2 composantes principales




Figure 12: biplot avec kmeans pour $k=3$

Conclusion : L'ACP est un outil permettant de pouvoir simplifier l'analyse des données et de réaliser des conjectures précises grâce à la simplification permise par la perte de dimensions.