

TP Clustering biostats


Emerick Lafortune

1 Introduction

La classification automatique est un type d'application de l'apprentissage supervisé, représentant un concept clé dans l'étude des données. La classification indique le problème de classer les données en deux catégories différentes. L'apprentissage supervisé est une méthode plus globale qui consiste à entraîner un modèle de données avec plusieurs fins en tête, comme par exemple pouvoir classer plusieurs catégories de nouvelles données grâce à notre modèle entraîné.

2 Enterotypes of the human gut microbiome

Les données étudiées dans cet exercice représentent 33 échantillons métagénomiques utilisés par la compagnie Sanger dans le cadre d'une étude. Chaque ligne représente une bactérie différente, et la première ligne contient des reads qui n'ont été affectés à aucun genre de bactérie.



Index	AM-F10-T1	AM-F10-T2	DA-AD-1	DA-AD-2	DA-AD-3	DA-AD-4	ES-AD-1	ES-AD-2	ES-AD-3
-1	0.481955	0.388583	0.533604	0.634708	0.77981	0.764099	0.251668	0.427127	0.39127
Bacteria	0	0	0	1.328e-05	0	0	0	0	0
Prosthecochloris	0	0	0	0	0	0	0	0	0
Chloroflexus	0	0	0	0	0	0	0	0	0
Dehalococcoides	9.59e-06	0	0	2.03e-05	0	8.728e-05	4.637e-05	0	0
Thermus	0	4.24e-06	0	0	0	0	0	0	0
Listeria	0	0	0	0	0	0	0	0	0
Fusobacterium	0	0	0	8.52e-06	0	0	0	0	0
Streptobacillus	0	4.71e-06	0	0	5.138e-05	0	0	0	0
Brevibacillus	0	0	0	2.37e-06	0	0	0	0	0
Acidobacteria_Gp1_Gp1	0	0	0	0	0	0	0	0	0
Paenibacillus	3.92e-06	0	5.52e-06	0	5.59e-06	3.97e-06	0	0	0
Bartonella	0	0	3.268e-05	0	0	3.945e-05	0	0	0
Beijerinckia	0	0	0	0	0	6.84e-06	0	0	0

Figure 1: Dataset initial

La première étape est de prétraiter ce dataset brut afin qu'il soit utilisable dans notre analyse de données. Nous allons retirer la première ligne qui n'est pas

exploitable et transposer le dataset, les variables étudiées étant les différentes familles de bactéries. On obtient le résultat ci-dessous, où nous avons 248 familles de bactéries différentes et 33 observations représentées par les lignes.

Index	Bacteria	sthecochl	hloroflexu	halococcoi	Thermus	Listeria	sobacteriu	eptobacill	revibacill	acteria_Gr	aenibacill	B
AM-F10-T1	0	0	0	9.59e-06	0	0	0	0	0	0	3.92e-06	0
AM-F10-T2	0	0	0	0	4.24e-06	0	0	4.71e-06	0	0	0	0
DA-AD-1	0	0	0	0	0	0	0	0	0	0	5.52e-06	3
DA-AD-2	1.328e-05	0	0	2.03e-05	0	0	8.52e-06	0	2.37e-06	0	0	0
DA-AD-3	0	0	0	0	0	0	5.138e-05	0	0	0	5.59e-06	0
DA-AD-4	0	0	0	8.728e-05	0	0	0	0	0	0	3.97e-06	3
ES-AD-1	0	0	0	4.637e-05	0	0	0	0	0	0	0	0
ES-AD-2	0	0	0	0	0	0	0	0	0	0	0	0
ES-AD-3	0	0	0	0	0	0	0	0	0	0	0	0
ES-AD-4	0	0	0	6.032e-05	0	0	2.181e-05	0	0	0	2.07e-06	0
FR-AD-1	0	0	0	0	0	0	0	0	0	0	1.469e-05	0
FR-AD-2	0	0	0	0	0	0	0	0	0	0	1.593e-05	0
FR-AD-3	0	0	0	4.266e-05	0	0	3.662e-05	0	0	0	8.8e-06	0
FR-AD-4	0	0	0	5.681e-05	0	0	4.468e-05	0	8.84e-06	0	4.508e-05	0

Figure 2: Dataset après nettoyage des données non utiles

Nous avons ensuite réparti ces 248 variables en 3 clusters en réalisant l'algorithme des k-means pour $k = 3$ et en déterminant, à l'aide de la fonction 'label' de la librairie sklearn, à quel cluster (0, 1 ou 2) appartient chaque variable. Cela a permis de réaliser une ANOVA sur ces trois groupes afin d'obtenir les p-values pour chaque variable. Les p-values sont un indice permettant d'évaluer la variabilité de chaque variable. En reportant dans une colonne les différentes valeurs des p-values dans l'ordre croissant, nous pouvons trouver la variable avec la p-value la plus faible, qui est celle avec la plus grande variabilité.

La variable avec la p-value la plus faible (la plus proche de 0) est Prevotella. Nous la choisissons donc pour réaliser notre boxplot, étant la variable la plus discriminante.

L'implémentation du critère ICL (Integrated Classification Likelihood) en Python permet d'évaluer le nombre de classes optimal pour notre modèle, basé sur le principe suivant : utiliser les mélanges de modèles gaussiens afin de trouver le meilleur équilibre entre la partition la plus fidèle aux données et celle la plus simple. Ce critère est évalué par un calcul algorithmique basé sur l'équation suivante :

Ainsi, nous réalisons le calcul de la variable BIC pour des valeurs de k entre 1 et 9 et trouvons que la valeur de k maximisant la valeur de BIC est $k = 4$. Nous déduisons donc que 4 est la valeur optimale de classes au sens du critère ICL.

Nous pouvons donc réaliser une ACP pour simplifier l'étude de nos données et leur visualisation en choisissant $k = 4$ composantes principales comme déterminé par le critère ICL. On observe ci-dessous la formation de nos différents clusters et la différence de population entre nos 3 clusters. De plus, nous pouvons voir que

sorted_anova_results - DataFrame	
Index	p-value
Prevotella	9.76613e-16
Bacteroides	4.24464e-10
Parabacteroides	0.000342716
Peptostreptococcus	0.000842791
Selenomonas	0.00157596
Bordetella	0.0202058
Porphyromonadaceae	0.0212021
Stackebrandtia	0.0212021
Kingella	0.0212021
Erythrobacter	0.0212021
Brachyspira	0.0212021
Syntrophus	0.0212021
Actinobacillus	0.0220477
Stenotrophomonas	0.0246559

Figure 3: Calcul des p-values par l'ANOVA réalisée sur notre dataset




Figure 4: Boxplot avec la variable Prevotella

$$BIC = -2 \log(L_c) + \nu \log(n)$$

avec L_c la vraisemblance classifiante, ν le nombre de paramètres libres du modèle et n le nombre d'observations considérée. Dans le cas particulier des kmeans $\nu = pk + 1$ (k centres et une variance commune), et

$$\log(L_c) = -\frac{1}{2} \left(np + np \log \frac{\text{trace}(S)}{p} \right) - n \log k + \frac{np}{2} \log 2\pi$$

avec p le nombre de variables, k le nombre de classes et S la matrice de variance intra-classe.

Figure 5: Formule du critère ICL (Integrated Classification Likelihood)

	k	BIC
0	1	-22414.186057
1	2	-35513.642851
2	3	-55687.683667
3	4	-56004.656504
4	5	-54970.891158
5	6	-39307.472552
6	7	-38514.269794
7	8	-37691.355650
8	9	-31565.486817

Le nombre optimal de clusters est : 4

Figure 6: Calcul du critère ICL (Integrated Classification Likelihood)

le cluster 0 est placé de manière symétrique par rapport à l'origine au cluster 1, ce qui permet de déterminer une similitude entre les bactéries des clusters 0 et 1.





Figure 7: Analyse en composantes principales pour $k = 4$ composantes principales

3 Compromis biais-variance en régression

Dans le cadre de l'étude des données de prostate, nous allons tester plusieurs modèles classiques et comparer leur performance afin d'évaluer la valeur du log de l'antigène lpsa. Ci-dessous, la forme de nos données :



lcavol	lweight	age	lbph	svi	lcp	gleason	pgg45	lpsa	train
-0.579818	2.76946	50	-1.38629	0	-1.38629	6	0	-0.430783	T
-0.994252	3.31963	58	-1.38629	0	-1.38629	6	0	-0.162519	T
-0.510826	2.69124	74	-1.38629	0	-1.38629	7	20	-0.162519	T
-1.20397	3.28279	58	-1.38629	0	-1.38629	6	0	-0.162519	T
0.751416	3.43237	62	-1.38629	0	-1.38629	6	0	0.371564	T
-1.04982	3.22883	50	-1.38629	0	-1.38629	6	0	0.765468	T
0.737164	3.47352	64	0.615186	0	-1.38629	6	0	0.765468	F
0.693147	3.53951	58	1.53687	0	-1.38629	6	0	0.854415	T
-0.776529	3.53951	47	-1.38629	0	-1.38629	6	0	1.04732	F
0.223144	3.24454	63	-1.38629	0	-1.38629	6	0	1.04732	F
0.254642	3.60414	65	-1.38629	0	-1.38629	6	0	1.26695	T
-1.34707	3.59868	63	1.26695	0	-1.38629	6	0	1.26695	T
1.61343	3.02286	63	-1.38629	0	-0.597837	7	30	1.26695	T
1.47705	2.99823	67	-1.38629	0	-1.38629	7	5	1.34807	T

Figure 8: Dataframe prostate

Le modèle classique de base est la régression linéaire, où l'on exprime une variable en particulier (variable cible) par rapport aux autres variables (variables explicatives). Les méthodes avant et arrière consistent, pour la méthode avant, à ajouter une à une nos variables explicatives pour voir si elles apportent des informations pour l'expression de notre variable cible, ou pour la méthode arrière, à commencer avec toutes les variables et à retirer celles qui impactent peu l'expression de la variable cible. L'importance des variables est mesurée grâce au calcul de leur p-value. Une p-value faible (proche de 0) indique une variable de grande importance, tandis que celles à p-value forte (proche de 1) sont les premières retirées pour la méthode arrière.

Après avoir isolé la variable cible des variables explicatives, nous pouvons déterminer un résumé pour connaître les p-values :

D'après le résumé, nous déduisons que lcavol et lweight sont les variables ayant le plus fort impact sur lpsa. Les variables svi et lbph ont également un fort poids sur notre variable cible. Cependant, nous remarquons que lcp, gleason et pgg45 ont des p-values d'un ordre de grandeur cent fois supérieur à celles des variables citées précédemment. Ainsi, dans le cadre de notre sélection basée sur la méthode arrière, nous retirons ces variables dont le poids est négligeable par rapport au reste.

Une évaluation avant et après avoir retiré les trois variables de faible poids montre que l'erreur quadratique et la valeur du R^2 restent quasiment les mêmes,

	coef	std err	t	P> t	[0.025	0.975]
lcavol	0.5616	0.085	6.601	0.000	0.393	0.731
lweight	0.6363	0.171	3.725	0.000	0.297	0.976
age	-0.0208	0.010	-1.991	0.049	-0.041	-4.7e-05
lbph	0.0939	0.054	1.743	0.085	-0.013	0.201
svi	0.7636	0.239	3.189	0.002	0.288	1.239
lcp	-0.1066	0.089	-1.194	0.236	-0.284	0.071
gleason	0.0652	0.103	0.635	0.527	-0.139	0.269
pgg45	0.0042	0.004	1.092	0.278	-0.003	0.012

Figure 9: Résumé donnant les valeurs des p-values

justifiant ainsi leur retrait du modèle. Les deux figures suivantes montrent la faible augmentation de la valeur de l'erreur quadratique moyenne en retirant les variables à faible poids :

Mean Squared Error: 0.3469917891761402
R² Score: 0.757517513020498

Figure 10: Évaluation du modèle avec toutes les variables explicatives

Mean Squared Error: 0.3528570945913284
R² Score: 0.7534187594236306

Figure 11: Évaluation du modèle en retirant pgg45, lcp et gleason

Nous allons maintenant comparer notre modèle linéaire aux modèles lasso et ridge, qui sont plus précis théoriquement.

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

Figure 12: Modèle de régression linéaire

Tandis que la régression linéaire est basée sur l'établissement d'une relation entre y et les différents coefficients de nos variables X_i , la régression Ridge utilise un facteur de correction avec un terme en λ servant à minimiser l'erreur. Ce terme est utile pour minimiser le surapprentissage, surtout lorsque le nombre d'observations est supérieur au nombre de variables et que les variables présentent des colinéarités multiples. Cela n'étant pas notre cas, notre modèle linéaire devrait présenter des résultats similaires au modèle ridge.

On peut voir que dans notre cas, nous avons trouvé une valeur d'erreur quadratique moyenne supérieure pour ridge que pour le modèle linéaire, mais

$$\text{Minimize } \left(\sum (y - \hat{y})^2 + \lambda \sum \beta_i^2 \right)$$

Figure 13: Modèle de régression ridge

selon le critère du R^2 , le ridge a un meilleur score que le modèle linéaire.

```
Mean Squared Error: 0.34871931522500876
R² Score: 0.7563102947930982
```

Figure 14: Évaluation du modèle ridge

Le modèle lasso présente également un terme de correction, mais il est plus utilisé lorsque le nombre de variables est important, car le terme de correction sélectionne le groupe de variables ayant le plus d'impact sur notre variable cible. Dans notre cas, nous obtenons une erreur quadratique importante et un critère du R^2 bien plus bas qu'avec les modèles linéaires et ridge. Cela montre que le modèle lasso est le moins performant dans le cadre de nos données, car nous cherchons à minimiser l'erreur quadratique moyenne et à maximiser le R^2 .

$$\text{Minimize } \left(\sum (y - \hat{y})^2 + \lambda \sum |\beta_i| \right)$$

Figure 15: Modèle de régression lasso

```
Mean Squared Error: 1.137259701476356
R² Score: 0.2052677632220039
```

Figure 16: Évaluation du modèle lasso

Ainsi, la comparaison des différents modèles donne le schéma suivant, où le modèle minimisant l'erreur dans notre cas est le modèle linéaire.

```
Linear Regression - CV MSE: 0.5782738071166469, Test MSE: 0.32289924481878285, Test R²: 0.7743537041226178
Ridge Regression - CV MSE: 0.6111491591481572, Test MSE: 0.34871931522500876, Test R²: 0.7563102947930982
Lasso Regression - CV MSE: 1.4071321212103909, Test MSE: 1.137259701476356, Test R²: 0.2052677632220039
```

Figure 17: Évaluation des différents modèles

4 Conclusion

Dans les deux études de données différentes que nous avons réalisées à travers les données de bactéries et les données de prostate, nous avons montré l'importance de l'utilisation de critères afin de vérifier d'une part la pertinence de nos modèles et d'autre part d'optimiser nos observations. Dans le cas de l'étude réalisée par la compagnie Sanger sur les bactéries, nous avons pu mettre en évidence d'énormes différences sur les p-values, montrant l'importance de certaines variables et la différence entre nos clusters. L'utilisation du critère BIC nous a permis de choisir le nombre optimal de clusters pour une meilleure représentation de nos données. Pour les données de prostate, l'utilisation de plusieurs modèles et des critères R^2 et de l'erreur quadratique moyenne nous a permis d'évaluer nos modèles et de choisir le modèle le plus pertinent à l'aide de nos mesures de précision.